

Aproximácia inverzného modelu pomocou umelej neurónovej siete a jej použitie na feedforward kompenzáciu pri riadení nelineárneho dynamického systému

Popis úlohy:

Cieľom práce je získať popis nelineárneho dynamického systému, ktorým je laboratórny model helikoptéry Humusoft CE 150, a následne preň navrhnúť riadenie využívajúce okrem PID regulátorov v spätnej väzbe aj feedforward kompenzáciu, ktorá zvyčajne vychádza z inverzného modelu dynamiky. Keďže však analytický popis inverzného modelu nie je k dispozícii, nahradený bude umelou neurónovou sieťou.



Obrázok 1) Laboratórny model helikoptéry Humusoft CE 150 [1]

Obsah

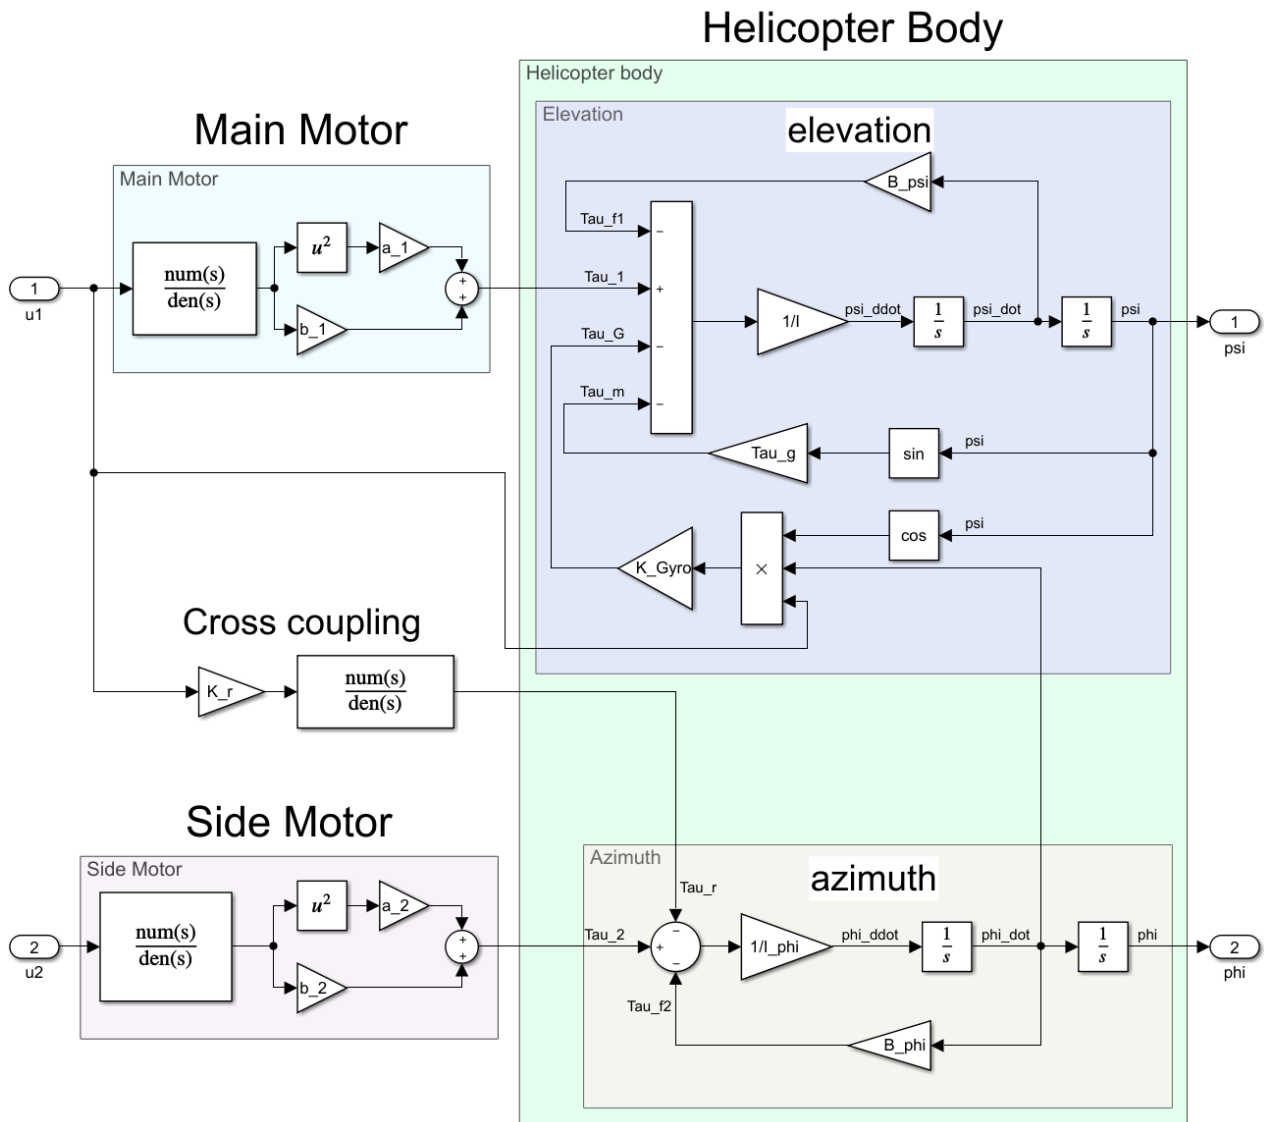
Prílohy.....	2
Model riadeného systému.....	3
Feedforward kompenzácia pomocou umelej neurónovej siete.....	5
1. Trénovanie neurónovej siete – čiastočná kompenzácia pri riadení elevácie	6
I) Trénovací dataset	6
II) Trénovanie siete a verifikácia výsledkov	6
2. Trénovanie neurónovej siete – kompenzácia pri riadení elevácie a azimutu	7
I) Trénovací dataset	7
II) Trénovanie siete a verifikácia výsledkov	7
3. Trénovanie neurónovej siete – kompenzácia v nestabilnej oblasti elevácie	10
I) Trénovací dataset	10
II) Trénovanie siete a verifikácia výsledkov	10
Záver	12
Zdroje.....	12

Prílohy

MeasuredDatasets -	priečinkok obsahujúci namerané datasety
TrainedNets -	priečinkok obsahujúci natrénované neurónové siete
<i>Main_HeliCE150_PID_FFCwithNN.m</i> -	skript prechádzajúci jednotlivé iterácie a trénovanie neurónových sietí krok za krokom (neobsahuje meranie tréningových datasetov, načítava ich z priečinku MeasuredDatasets)
<i>prepTrainTestData.m</i> -	funkcia, ktorá zamieša a rozdelí namerané datasety na tréningové a testovacie
<i>Model_HeliCE150_PID_FFCwithNN.slx</i> -	dynamický model riadenej helikoptéry, ktorý simuluje jednotlivé iterácie (je volaný z hlavného skriptu <i>Main_HeliCE150_PID_FFCwithNN.m</i>)
<i>TestModel_HeliCE150_PID_FFCwithNN.slx</i> -	interaktívny testovací model, v ktorom možno priamo počas simulácie zadávať žiadané hodnoty elevácie a azimutu a testovať tak riadiaci algoritmus a natrénované neurónové siete
<i>Param_HeliCE150_PID_FFCwithNN.m</i> -	naestimované parametre nelineárneho dynamického modelu helikoptéry (volá sa pri inicializácii testovacieho modelu <i>TestModel_HeliCE150_PID_FFCwithNN.slx</i>)

Model riadeného systému


Dynamický model vychádzajúci z diferenciálnych rovníc má radu výhod, avšak popísať zložitejší systém môže byť komplikované a v prípade, že sú niektoré jeho parametre neznáme, až nemožné. Rovnako je to v prípade modelu uvažovanej helikoptéry, a preto sa v práci bude vychádzať z naestimovaného empirického modelu, popísaného v [2], pričom sa bude predpokladať, že tento model dostatočne popisuje dynamické vlastnosti reálneho systému.



Obrázok 2) Bloková schéma nelineárnej dynamiky - empirický model


Model na Obrázok 2 využíva k popisu dynamiky hlavnej aj vedľajšej vrtule ventilátorovú charakteristiku a tiež prenosové funkcie s oneskorením 2. rádu. Uholové zrýchlenie vo vertikálnom smere, z ktorého sa určuje uhol elevácie značený ψ , je ovplyvnené momentom od hlavnej vrtule τ_1 , momentom viskózneho tlmenia τ_{f1} aj momentom od tiažovej sily τ_m . Uholové zrýchlenie v horizontálnej rovine, ktoré určuje azimut značený ϕ , je závislé na momente vedľajšej vrtule τ_2 a momente viskózneho tlmenia τ_{f2} . Okrem toho sú oboje časti, dynamika vertikálneho a horizontálneho natočenia navzájom previazané. Účinok rotácie hlavnej vrtule sa prejaví na horizontálnom zrýchlení cez reakčný moment motora τ_r a naopak vzájomná rotácia generuje gyroskopický moment τ_g pôsobiaci vo vertikálnom smere. Toto vzájomné previazanie komplikuje riadenie systému a bude musieť byť zohľadnené nielen pri generovaní dát na tréningovanie neurónovej siete, ale aj pri návrhu vhodných PID regulátorov.

Fyzický model helikoptéry umožňuje jej náklon vo vertikálnej rovine od 45° do 135° , ak uvažujeme uhol elevácie ψ tak, ako je vyznačený na nasledujúcom ilustračnom obrázku.



Obrázok 3) Elevácia ψ – uhol natočenia vo vertikálnej rovine

Pokiaľ uhol ψ je v intervale $< 45^\circ; 90^\circ >$, tak z hľadiska riadenia elevácie je systém stabilný v zmysle, že s narastajúcim ψ sa tiež zvyšuje moment od tiažovej sily a na dosiahnutie vyššieho uhlu ψ preto treba vyššie napätie na hlavnom motore. Keď elevácia ale prekročí hranicu 90° , záťaž momentu od tiažovej sily sa začne znižovať a predpoklad, že na zdvihnutie helikoptéry do väčšej výšky potreba väčšie otáčky vrtule už tak úplne neplatí. Z tohoto hľadiska je systém v intervale $\psi \in < 90^\circ; 135^\circ >$ nestabilný a pomocou samotného PID regulátora alebo samotného inverzného modelu bez plánovania trajektórie sa nedá riadiť. Hoc i len malý prechyt od žiadanej hodnoty v nestabilnej oblasti má za následok, že pri napájaní konštantným napätím sa helikoptéra nakloní viac a znižujúca sa záťaž spôsobí, že vyletí až na horný doraz. To spôsobí značné problémy pri snahe získať požadované dáta na tréning neurónovej siete.

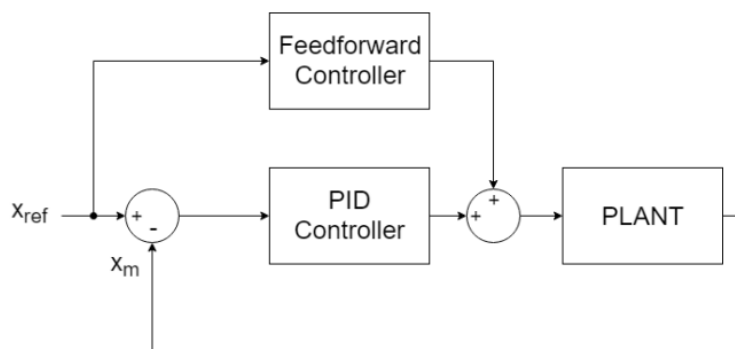


Obrázok 4) Azimut ϕ - uhol natočenia v horizontálnej rovine

Z hľadiska natočenia v horizontálnej rovine je situácia menej komplikovaná, uhol ϕ sa môže meniť v plnom rozsahu $< -130^\circ; 130^\circ >$ a azimut je stabilný.

Feedforward kompenzácia pomocou umelej neurónovej siete

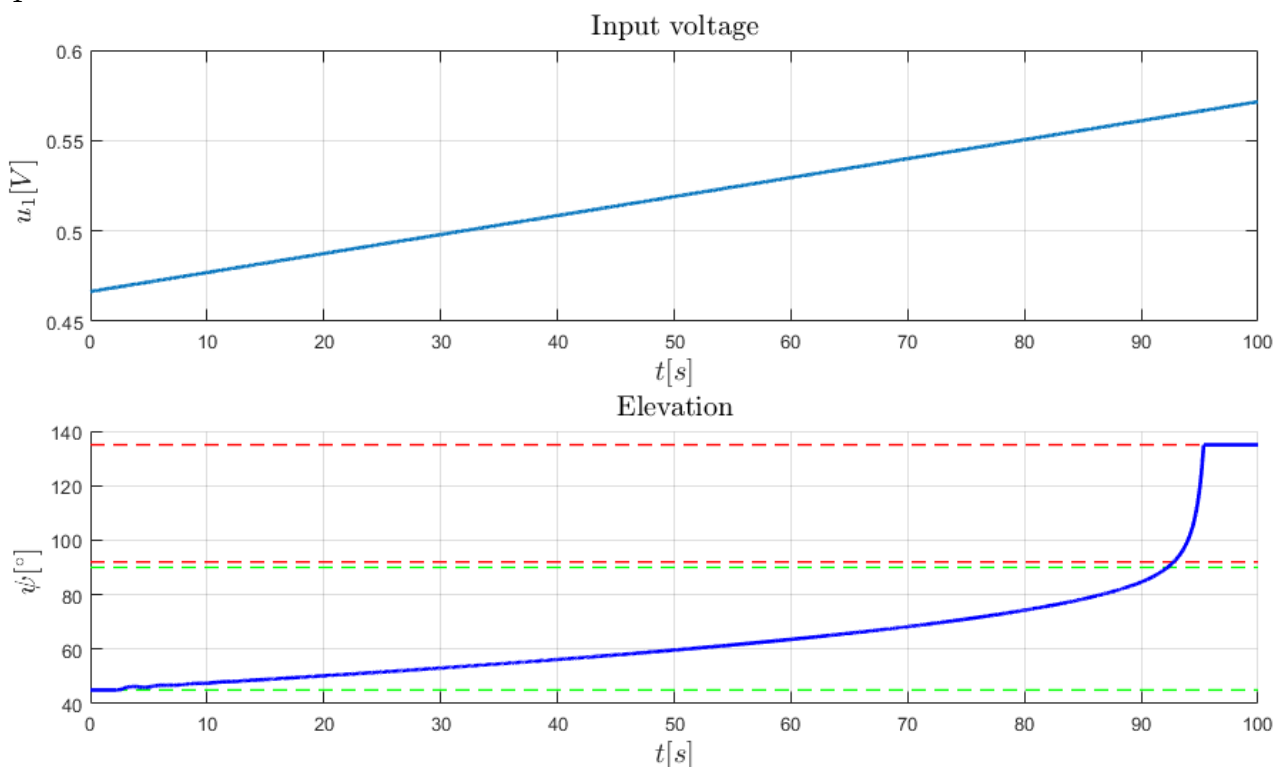
Základná myšlienka využitia umelej neurónovej siete v tomto prípade spočíva v nahradení inverzného modelu dynamiky, ktorý je potrebný vo feedforward kompenzácii. Schéma feedforward riadenia spolu so spätnou väzbou využívajúcou PID regulátor vidno na Obrázok 5.



Obrázok 5) PID regulátor s feedforward kompenzáciou [3]

Zjednodušená predstava je, že stačí natrénovať neurónovú sieť tak, aby keď na jej vstup dáme požadované uhly elevácie a azimutu, vráti nám potrebné hodnoty napätí na motorčekoch helikoptéry. K tomu je nutné namerať vstupné napätia u_1 a u_2 , im odpovedajúce hodnoty uhlov ψ a ϕ a predložiť tieto dáta neurónovej sieti presne naopak ako je to v prípade modelu systému, teda aby fungovala ako inverzný model dynamiky, hoci len statický. Tým pádom vhodne navrhnutý PID regulátor umožní riadiť systém a vysporiadať sa s prechodnými dejmi, zatiaľ čo natrénovaná neurónová sieť bude kompenzovať nelinearity.

Nasledujúci graf ukazuje odozvu elevácie ψ pri postupne sa zvyšujúcom napájacom napätí hlavného motora u_1 .




Obrázok 6) Zmena elevácie pri pomalom náraste napätia

Vertikálny náklon helikoptéry sa najskôr menil postupne kým sa nepriblížil k hranici 90° . Vtedy došlo podľa očakávaní k rýchlemu nárastu a helikoptéra sa ustálila až na nežiadúcej hornej krajnej polohe. Z grafu je zrejmé, že takýto dataset nie je ako celok vhodný na tréning neurónovej siete, pretože hodnoty napätia u_1 v oblasti $\psi \in < 90^\circ; 135^\circ >$ neodpovedajú príslušnému uhlu elevácie, ako by to malo byť v prípade požadovaného inverzného modelu.

1. Trénovanie neurónovej siete – čiastočná kompenzácia pri riadení elevácie

I) Trénovací dataset

V prvej iterácii bude využité jednoduché riadenie v otvorenej smyčke s pomaly narastajúcim napätím, aby nedošlo k rýchlym prechodovým dejom ako vidno na prvých 2 grafoch v Obrázok 7. Natočenie helikoptéry v horizontálnom smere ϕ bude zatiaľ fixované a teda nebude sa uvažovať. Uhol ψ sa mení len v rozsahu stabilnej oblasti a hodnota napätia je normalizovaná.




Obrázok 7) Trénovací dataset - kompenzácia pri riadení elevácie

Trénovací dataset vidno na spodnom grafe, ktorý vyjadruje nelineárnu závislosť potrebného napätia primárnej vrtule na udržanie helikoptéry v rôznych hodnotách elevácie.

II) Trénovanie siete a verifikácia výsledkov

Natrénovaním jednoduchkej feedforward siete (perceptrón s 1 skrytou vrstvou a 5 neurónmi), je následne možné riadiť eleváciu vo veľkej časti stabilnej oblasti, navyše bez nutnosti využiť regulátor v uzavretej smyčke.



Obrázok 8) Feedforward riadenie elevácie v otvorenej smyčke


Ako možno vidieť na Obrázok 8, problém opäť nastal až v blízkosti vodorovnej polohy, na ktorej sa helikoptéra nedokázala udržať. Napriek tomu natrénovaná sieť zatiaľ posluží ako vhodná feedforward kompenzácia pri meraní tréningových dát v nasledujúcej iterácii.

2. Trénovanie neurónovej siete – kompenzácia pri riadení elevácie a azimutu

I) Tréningový dataset

Cieľom v tomto kroku je využiť natrénovanú sieť, doplniť ju o PID regulátor na riadenie elevácie a jednotlivo naladiť koeficienty druhého PID regulátora v spätnej väzbe riadiaceho azimutu. Vhodne namerané dáta budú použité na trénovanie novej feedforward siete, ktorá by už mala byť schopná kompenzovať nelinearity pri riadení oboch uhlov ψ aj ϕ .

Keďže azimut je stabilný v celom pracovnom rozsahu, tréningový dataset bude rozdelený do 3 meraní, pričom PID regulátor bude individuálne naladený tak aby bol schopný udržať približne konštantný azimut $\phi = -90^\circ, 0^\circ$ a 90° .



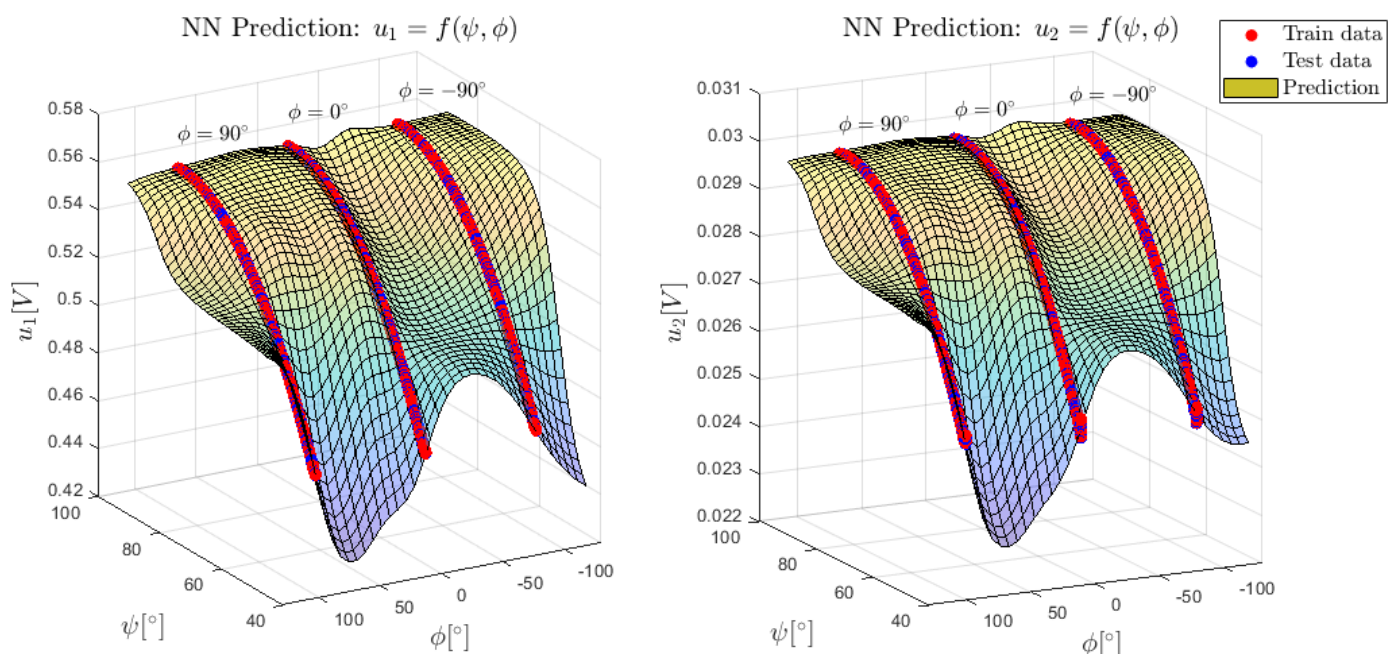
Obrázok 9) Tréningový dataset - kompenzácia pri riadení elevácie a azimutu (stabilná oblasť elevácie)

Na Obrázok 9 vidno trojicu nameraných dát, ktoré vyjadrujú závislosť napätí motorčekov na odpovedajúcich hodnotách uhlov ψ a ϕ . Elevácia sa podobne ako v predošlom prípade postupne menila v celom stabilnom rozsahu ako vyznačuje zelený rámik pre $\psi \in < 45^\circ; 90^\circ >$ a $\phi \in < -130^\circ; 130^\circ >$. Z tréningových datasetov bola odstránená nežiadúca časť zachytávajúca prechodné dynamické deje.

II) Trénovanie siete a verifikácia výsledkov

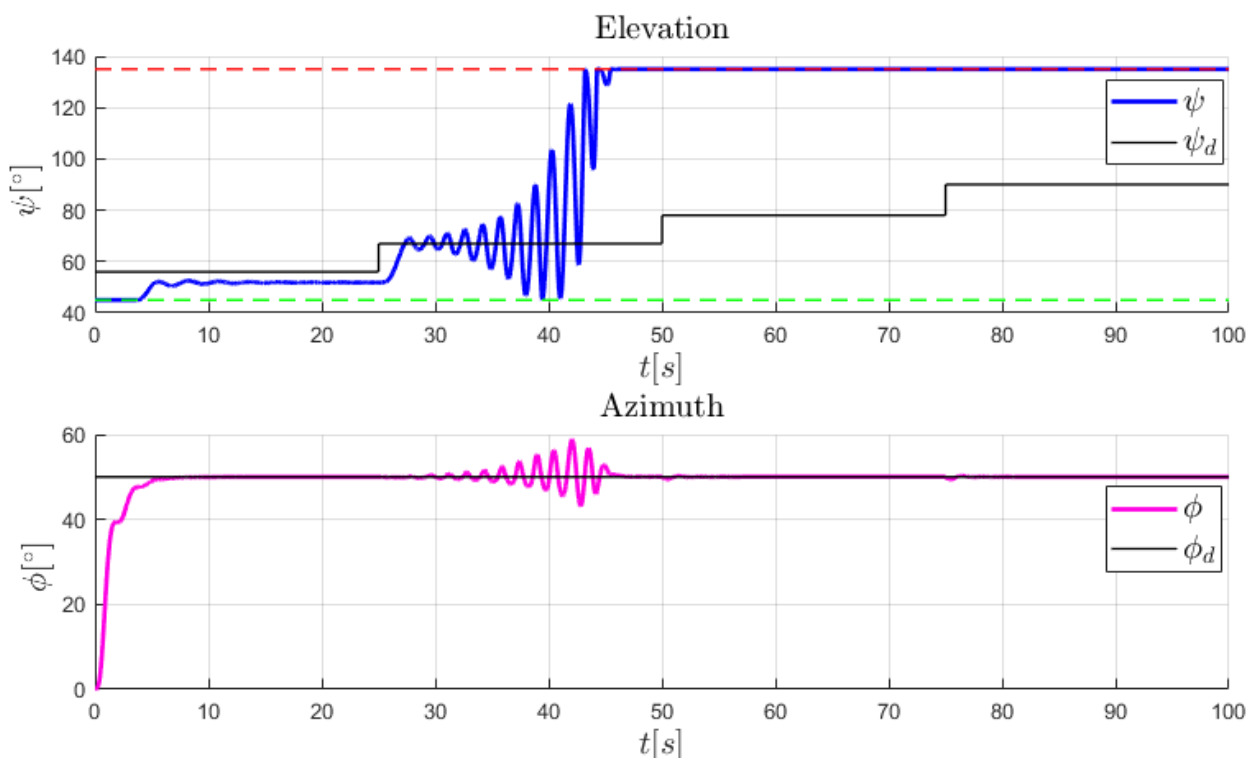
V tomto prípade bude mať štruktúra siete 2 vstupy odpovedajúce požadovaným uhlom a 2 výstupy, reprezentujúce potrebné napätia motorčekov. Vhodný počet skrytých vrstiev a neurónov feedforward siete bude hľadaný iteratívne pomocou testovania natrénovanej siete a vykreslenia jej odhadov v celom pracovnom rozsahu azimutu.

Na Obrázok 10 vidno predikované hodnoty potrebných napätí, ktoré boli určené pomocou natrénovanej feedforward siete s 2 skrytými vrstvami a počtom neurónov 10 a 5. Predikované hodnoty tvoria 3D plochy pričom vidno, že v oblasti tréningových dát prechádzajú nameranými krivkami. Pri pohľade na tvar plochy možno predpokladať, že odhadnuté hodnoty zrejme nebudú úplne presné, pretože plocha je značne zvlnená. Aké sú správne hodnoty medzi nameranými bodmi nemožno povedať, keďže pre tie nemáme namerané dáta. Natrénovaná neurónová sieť bola preto implementovaná vo feedforward kompenzácii a bolo otestované riadenie systému.



Obrázok 10) Predikcia napätí u_1 a u_2 (feedforward net [10,5] hidden neurons)

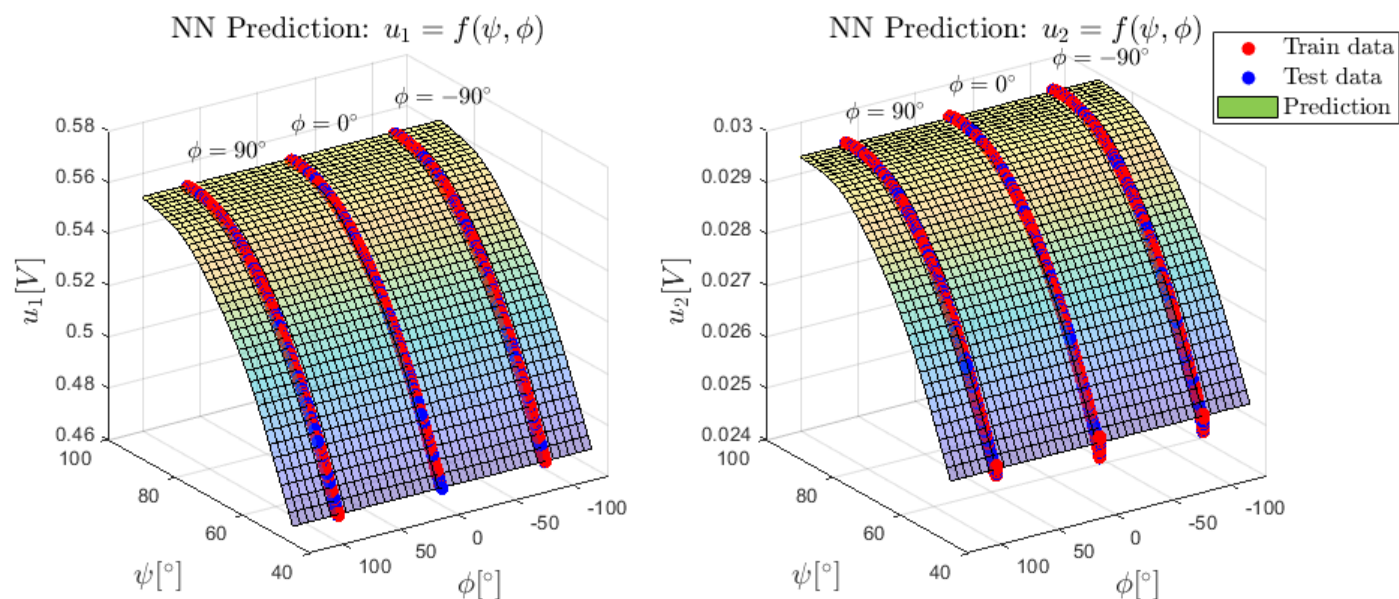
Obrázok 11 zobrazuje riadenie systému s natrénovanou neurónovou sieťou pre postupne sa meniaci uhol elevácie, pričom žiadaný azimut bol zámerne zvolený na hodnotu $\phi_d = 50^\circ$, pretože v tejto časti vykazuje natrénovaná neurónová sieť podľa Obrázok 10 pomerne veľké zvlnenie, ktoré by nemuselo odpovedať skutočnosti.



Obrázok 11) Riadenie elevácie a azimutu pomocou PID regulátorov s feedforward kompenzáciou (feedforward net [10,5] hidden neurons)

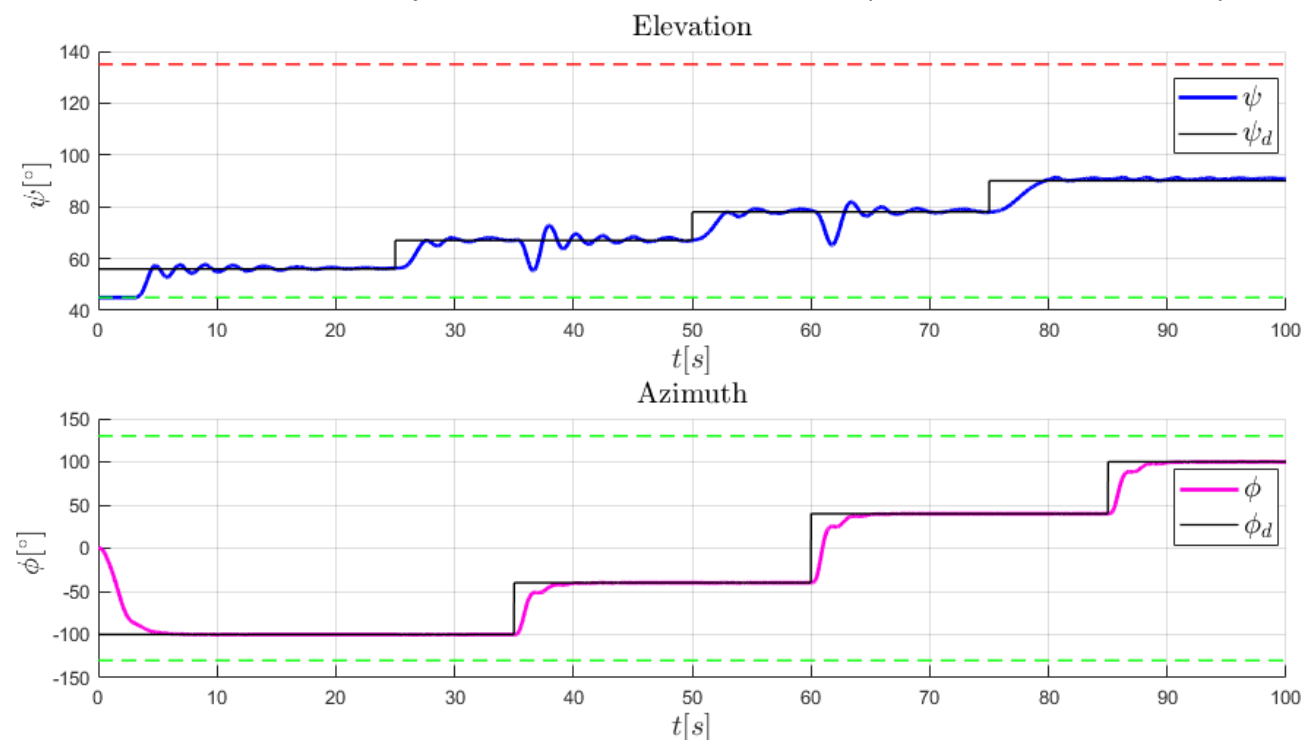
Po odsimulovaní riadenia sa potvrdilo očakávanie, že v oblasti medzi nameranými hodnotami nepredikovala sieť potrebné hodnoty napätia dostatočne presne. Uhol elevácie v počiatočných sekundách nedosahuje žiadajú hodnotu a pri prvej zmene ψ_d došlo k väčšiemu rozkmitaniu helikoptéry až sa ustálila na hornej krajnej polohe. V prípade azimutu si regulátor v spätnej väzbe dokázal poradiť s nepresnosťami feedforward kompenzácie a azimut udržal na žiadanej hodnote 50° .

Ďalšie iterácie tréningu siete potvrdili, že pre túto aplikáciu bude vhodnejšia sieť s jednoduchšou štruktúrou. Pri použití rovnakého tréningového datasetu bola natrénovaná sieť len 2 neurónmi v 2 skrytých vrstvách. Výsledok predikcie hodnôt napätí v stabilnom rozsahu vyzerá nasledovne:



Obrázok 12) Predikcia napätí u_1 a u_2 (feedforward net [2,2] hidden neurons)

Predikované hodnoty mimo nameraných dát sú výrazne menej zvlnené. Či je to vyhovujúce by bolo možné overiť meraním ďalších dát, avšak jednoduchšie riešenie bude otestovať priamo riadenie samotného systému.



Obrázok 13) Riadenie elevácie a azimutu pomocou PID regulátorov s feedforward kompenzáciou (feedforward net [2,2] hidden neurons)

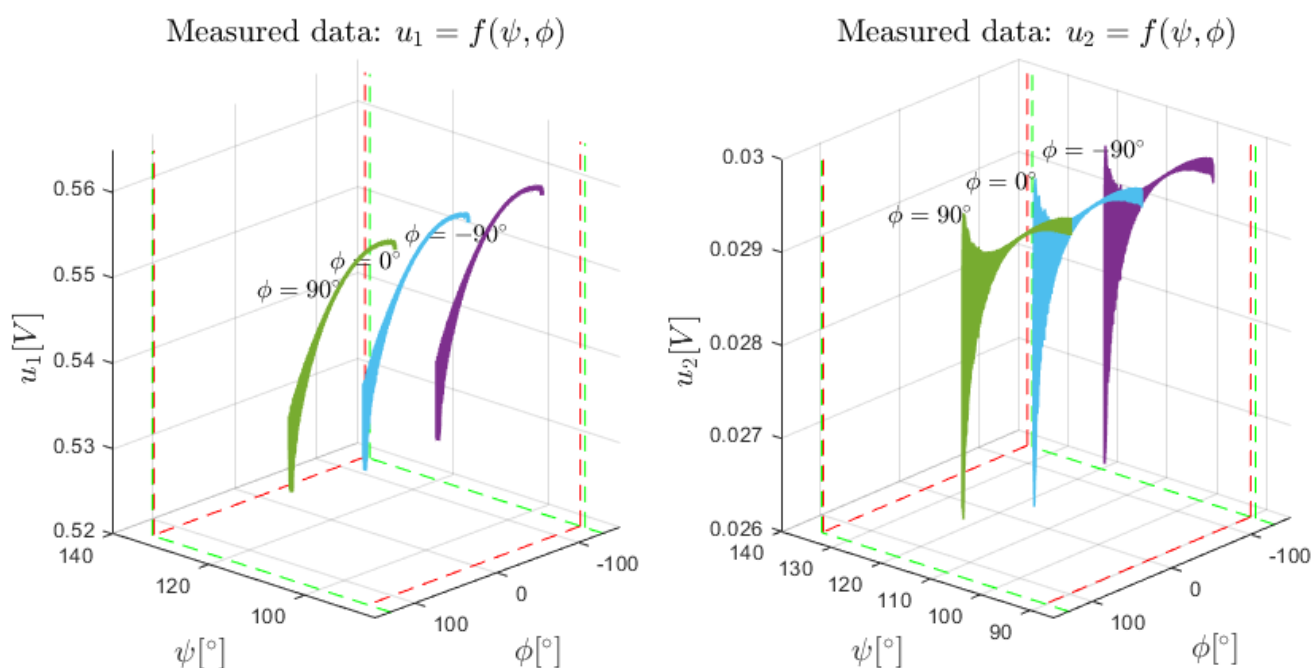
Hoci na základe Obrázok 13 nie je riadenie optimálne, pretože elevácia značne kmitá okolo žiadaných konštantných hodnôt, toto správanie je spôsobené PID regulátormi v spätnej väzbe. Tie sú z hľadiska riadenia oboch uhlov súčasne potrebné, kvôli cross-couplingu a previazanosti ich dynamiky. Výkmity elevácie totiž presne odpovedajú momentom kedy dochádza k zmene žiadaného azimutu, pričom samotná neurónová sieť vo feedforward kompenzácií by si s prechodnými dejmi neporadila.

3. Trénovanie neurónovej siete – kompenzácia v nestabilnej oblasti elevácie

I) Trénovací dataset

Najnovšie natrénovaná sieť z predošlej iterácie umožnila spolu s dvoma PID regulátormi súčasné riadenie elevácie a azimutu v stabilnej časti pracovného rozsahu.

K nameraniu potrebných trénovacích dát v nestabilnej oblasti však bolo nevyhnutné helikoptéru aspoň v časti tohto intervalu uradiť. To bolo nakoniec možné až využitím natrénovanej neurónovej siete a vyladeným gain-scheduled PD regulátorom, ktorého parametre sa v priebehu riadenia mierne menili. Veľmi pomalým zvyšovaním žiadanej elevácie za hranicu 90° sa podarilo namerať dáta pre rozsah $\psi \in < 90^\circ; 115^\circ >$, teda pre viac ako polovicu rozsahu v nestabilnej oblasti. Problémom pri riadení v nestabilnej oblasti pomocou PD regulátora však bolo neustále oscilovanie helikoptéry okolo žiadanej hodnoty a natrénovaná sieť z neupraveného datasetu nepredikovala dostatočne presné hodnoty. Dataset bol z toho dôvodu upravený čiastočným filtrovaním a výsledný trénovací dataset vyzeral nasledovne:



Obrázok 14) Trénovací dataset - kompenzácia pri riadení elevácie a azimutu (nestabilná oblasť elevácie)


Namerané dáta, ktoré vidno na Obrázok 14, nie sú pre trénovanie feedforward siete ideálne, pretože hodnoty napätí u_1 , u_2 sa aj pri malej zmene uhlov ψ , ϕ menia v relatívne veľkom rozsahu. O to dôležitejšie bude zvoliť vhodný počet skrytých vrstiev a tiež počet neurónov.

II) Trénovanie siete a verifikácia výsledkov

Po niekoľkých pokusoch testovania rôznych štruktúr siete bol zvolený variant s 3 skrytými vrstvami a počtom neurónov 2,1,2. Opäť sa potvrdilo, že menší počet neurónov na skrytých vrstvách lepšie predikuje potrebné hodnoty napätí aj mimo nameraných trénovacích dát.

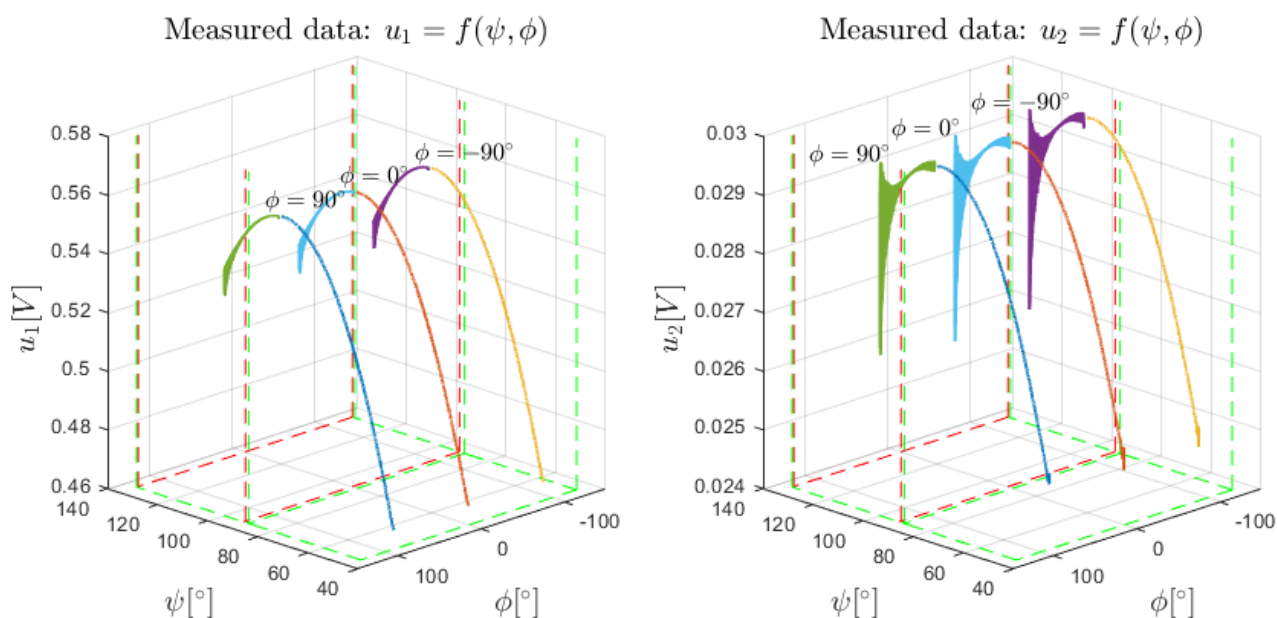
Natrénovaná sieť bola následne pridaná do modelu a radiaci algoritmus bol upravený tak, aby v závislosti na žiadanej elevácii využíval na feedforward kompenzáciu odpovedajúcu sieť. Teda pre $\psi \in < 45^\circ; 90^\circ$) natrénovanú sieť z predošlého kroku a pre $\psi \geq 90^\circ$ sieť natrénovanú na nestabilnú oblasť pracovného rozsahu elevácie.

Z grafov na Obrázok 15 je zrejmé, že využitím oboch sietí s vyladenými PD regulátormi bolo možné riadiť eleváciu helikoptéry takmer až na hodnotu 110° , hoci na tejto hodnote sa ju podarilo udržať len niekoľko sekúnd. Podobne ako pri meraní trénovacích dát, v nestabilnej oblasti helikoptéra okolo žiadanej hodnoty oscilovala a pomocou PD regulátora sa toto správanie nepodarilo eliminovať. V stabilnej časti sa opäť prejavil cross-coupling, ktorý už ďalej nebol tak výrazný pretože žiadaný azimut bol konštantný.



Obrázok 15) Riadenie elevácie a azimutu pomocou PD regulátorov s feedforward kompenzáciou v stabilnej aj nestabilnej oblasti

Predtým než by sa opäť ladili regulátory, aby bolo možné namerať nové dáta v ešte väčšom intervale pracovného rozsahu, sa ponúka možnosť nahradiť použité neurónové siete vo feedforward kompenzácii jednou sieťou, ktorá by bola natrénovaná na kombinovanom datasete, ktorý jednoducho vznikne spojením tých predošlých tak, ako vidno na nasledujúcom obrázku:



Obrázok 16) Trénovací dataset - kompenzácia pri riadení elevácie a azimutu (stabilná a nestabilná oblasť elevácie)

Po niekoľkých pokusoch rôznych štruktúr však nebola sieť natrénovaná na tomto datasete z hľadiska riadenia tak dobrá ako dve samostatné siete. V snahe ešte viac rozširovať interval, v ktorom bude možné helikoptéru riadiť by bolo preto potrebné naďalej experimentovať s ladením regulátorov, prípadne zvoliť iný typ umelej neurónovej siete, ako napríklad NARX.

Záver

V úvodnej časti práce bol použitý dynamický model helikoptéry Humusoft CE 150, vychádzajúci z empirického modelu a naestimovaných parametrov. Dynamický systém bol preskúmaný z hľadiska riadenia a súčasne boli identifikované intervaly pracovného rozsahu, v ktorých bolo možné predpokladať, že by sa v nich dalo helikoptéru riadiť pomocou PID regulátorov a feedforward kompenzácie. K získaniu inverzného modelu systému, potrebného do feedforward kompenzácie, bola využitá umelá neurónová sieť.

Proces získavania tréovacích dát ako aj samotný tréning siete bol iteratívny. V niekoľkých krokoch bolo vždy potrebné najskôr naladiť regulátory tak, aby bolo možné riadiť helikoptéru aspoň v nejakej časti pracovného rozsahu. Pre príslušný interval boli následne namerané tréovacie datasety. Každá aktuálne natrénovaná sieť bola implementovaná vo feedforward kompenzácii, parametre regulátorov boli pozmenené a tým bolo možné riadiť helikoptéru opäť vo väčšom rozsahu a namerať tak nové dáta, použiteľné pri ďalšom tréovaní.

Takýmto postupom boli natrénované dve umelé neurónové siete, pomocou ktorých bol riadený azimut helikoptéry v celom pracovnom rozsahu. Eleváciu sa podarilo riadiť v celom stabilnom intervale a dokonca aj v značnej časti nestabilnej oblasti, hoci v takom prípade bolo riadenie menej robustné.

O procese tréovania zároveň možno povedať, že nie je ukončený, ale k pokračovaniu je potrebné opäť rozšíriť rozsah nameraných hodnôt. V priebehu testovania rôznych štruktúr sietí sa ukázalo, že pre túto aplikáciu dávali jednoduchšie siete zvyčajne lepšie výsledky, čo je užitočný poznatok, z ktorého možno vychádzať aj do budúcnosti. Okrem toho, súčasťou experimentovania bolo aj využitie iného typu umelej neurónovej siete, ktorou je nelineárna autoregresívna neurónová sieť s externým vstupom (NARX). Dynamická sieť je z teoretického hľadiska vhodná práve pre aplikácie s dátami nameranými v časových radách a pri predikcii výstupných hodnôt dokáže zohľadniť aj niekoľko za sebou nasledujúcich vstupov. Takáto sieť nemusí nevyhnutne nahradiť použité statické varianty ale môže slúžiť ako doplnok na kompenzáciu prechodných dynamických dejov.

Hoci nebolo možné korektne zhodnotiť vhodnosť riadiaceho algoritmu, pretože na testovanie aj meranie dát by bolo potrebné mať k dispozícii skutočný laboratórny model. Napriek tomu práca poskytuje jednu z možností využitia umelých neurónových sietí pri riadení nelineárneho dynamického systému s neznámymi parametrami.

Zdroje

- [1] Application of predictive control to a toy helicopter. ResearchGate [online]. [cit. 2021-6-18]. Dostupné z: https://www.researchgate.net/publication/3970679_Application_of_predictive_control_to_a_toy_helicopter
- [2] CE 150 HELICOPTER MODEL. [Http://control.dii.unisi.it/](http://control.dii.unisi.it/) [online]. [cit. 2021-6-18]. Dostupné z: http://control.dii.unisi.it/cmr/altro/heli_ce150_manual.pdf
- [3] M. Rajchl and M. Brabc, "Inverse Model Approximation Using Iterative Method and Neural Networks with Practical Application for Unstable Nonlinear System Control," *2018 18th International Conference on Mechatronics - Mechatronika (ME)*, 2018, pp. 1-7.